

ARQUITETURA TESE

Sistema neurossimbólico de apoio à qualificação
do risco de violência recorrente contra a mulher

Relatório Metodológico do Smoke Test — Seção 4 do DDA v5.3

Protótipo integralmente reproduzível sobre dados sintéticos.
Este documento descreve dados, métodos, resultados medidos e limitações declaradas.

Ambiente de execução: ASUS ROG Strix SCAR 18 — Intel Core Ultra 9 275HX,
RTX 5090 Laptop (24 GB), 64 GB RAM, Windows 11, Python 3.14.7,
Ollama 0.35.1 + mistral:7b (Q4, 100% GPU), BGE-M3 (CPU), faiss-cpu 1.15.1, LightGBM 4.7

1. Escopo e fontes de dados

O objetivo do smoke test é validar a arquitetura de ponta a ponta — não estabelecer validade externa. Todas as fontes são sintéticas ou públicas oficiais; nenhum dado real de tribunal foi utilizado (o acordo CNJ/TJAM tramita fora do escopo).

1.1 Base tabular (fonte única)

base_sintetica_risco.xlsx: 20.200 episódios de violência doméstica com alvo binário nova_agressao (10.217 positivos / 9.983 negativos $\approx$ 50/50), 14.591 agressores e 14.592 vítimas com identificadores sintéticos estáveis — o que permite partição por grupo e impede vazamento de entidade entre treino e teste.

O modelo utiliza 15 features lógicas (11 numéricas/binárias — histórico, ameaça de morte, arma, álcool/drogas, separação recente, descumprimento de medida protetiva, filhos comuns, desemprego, controle coercitivo — e 4 categóricas). Três colunas são proibidas por constituírem vazamento (artefatos do gerador): prob_geracao, score_geracao, perfil_risco_agressor. O dicionário completo está em dados/dicionario_base.md.

1.2 Narrativas e corpus legal


Decisão D7-b: como não há texto real no escopo, 1.500 narrativas sintéticas (boletins de ocorrência, depoimentos, pedidos de medida protetiva, históricos forenses) foram geradas a partir dos próprios registros tabulares e vinculadas pelos mesmos ids de vítima/agressor — simulando o ramo textual sem sair da base.

O corpus legal contém 22 dispositivos com texto oficial extraído do Planalto (Código Penal, Lei 11.340/2006, Decreto-Lei 3.688/1941), em conjuntos/corpus_legal.jsonl. O gold set de recuperação tem 400 consultas derivadas das narrativas (200 dev / 200 test), com rótulos fracos por regras feature→dispositivo e mascaramento de auto-match (a narrativa-fonte da consulta é excluída do ranking).

2. Arquitetura (D1–D9)

Pipeline neurossimbólico: componentes de dados produzem score e evidências; componentes determinísticos decidem nível, incerteza e revisão humana. O LLM só escreve texto — nunca decide risco (D9-b).

Pipeline JUDICATA — caminho síncrono (SLA 8,5 s)



D9-b: LLM gera só texto — score, nível, incerteza e fundamentação são determinísticos

Figura 1 — Arquitetura ponta a ponta com latências medidas por estágio.

Decisões-chave: D2=BGE-M3 (decidido por ablação, não por prior), D6=ramo denso isolado (fusão RRF rejeitada por piorar o resultado), D7-b=narrativas vinculadas à base, D8=bandas 0,25/0,50/0,75 provisórias com override para revisão humana, D9-b=LLM restrito a campos textuais do schema Toulmin.

3. Ramo tabular — LightGBM (§4.5)

3.1 Protocolo

Partição externa 80/20 por grupo de agressor (GroupShuffleSplit, seed 42, grupos verificados disjuntos em código): 16.207 episódios de treino e 3.993 de holdout. O número de árvores é escolhido por early stopping (teto 2.000, paciência 50) sobre validação interna de 15% do treino (2.452 episódios, também por grupo) — o holdout final jamais participa da seleção do ponto de parada. Hiperparâmetros: learning_rate 0,05, num_leaves 31, subsample 0,9, colsample_bytree 0,9.

3.2 Resultados

Métrica	300 árvores fixas	Early stopping (it. 54)	Critério
AUC (holdout)	0,744	0.751	reportado
Brier	0,204	0.201	reportado
ECE	0,021	0.012	$\leq 0,05$ — OK
Árvores efetivas	300	54	—

O early stopping sobre validação interna removeu ~150 árvores redundantes e melhorou simultaneamente discriminação (+0,007 AUC) e calibração (ECE reduzido quase à metade) — evidência de que o modelo fixo de 300 árvores estava levemente sobreajustado.

Fase 1 — Modelo tabular sem vazamento (artefatos banidos por construção)




Figura 2 — ROC do holdout (AUC 0.751) e importância por permutação. A caixa vermelha mostra o modelo-controle COM artefatos de geração.

Anti-vazamento (§4.5): nenhum artefato de geração entra no modelo de produção. O controle deliberadamente contaminado mostra score_geracao com importância 0,229 (~5× o resto somado) — prova de que o teste de permutação flagra vazamento quando presente.

Treino LightGBM — early stopping it. 54, gap treino/validação +0.035 AUC | holdout externo (teste): 0.751




Figura 3 — Convergência do treino: log-loss e AUC em treino vs. validação interna por grupo; a linha tracejada marca o early stopping (it. 54).




Figura 4 — Curva de aprendizado (AUC vs. tamanho do treino) e AUC do probe CAV por conceito nos 5 folds de validação.




Figura 5 — Diagrama de confiabilidade: ECE 0.012 (limiar 0,05).




Figura 6 — Distribuição dos scores do holdout nas faixas de decisão D8.

Leituras honestas: a curva de aprendizado ainda sobe (dados adicionais ajudariam, com retorno decrescente); o gap treino/validação residual é +0,035 AUC no ponto de parada; a prevalência artificial de ~50% torna os limiares D8 provisórios — recalibração e novo ponto de operação (recall alvo §8) são obrigatórios com dados reais.

3.3 O que a classificação acerta e erra — casos concretos




Figura 6b — Matriz de confusão real no holdout (limiar 0,50): acurácia 69,0%, recall 64,5%, precisão 71,2%.

Caso	Score	Banda D8	Padrão de features	Desfecho
TP EP013595	0,901	crítico	ameaça+arma+separação+descumprimento+coerção	correto
FP EP013146	0,841	crítico	separação+descumprimento+coerção (sem ameaça/arma)	falso positivo
FN EP017662	0,311	moderado	só coerção+filhos (padrão oculto ao tabular)	falso negativo
TN EP002641	0,219	baixo	nenhum fator de risco	correto

Os erros são interpretáveis: o FP acumula fatores graves sem os dois mais fortes (ameaça de morte e arma) — a banda CRÍTICO dispara revisão humana, que é o comportamento seguro para o erro. O FN mostra o limite do tabular: controle coercitivo isolado tem peso insuficiente — risco residual que justifica o recall-alvo §8 e a revisão obrigatória em MODERADO divergente (override §5.3). Detalhes completos em [decisoões/exemplos_classificacao.md](#) e [dados/exemplos/](#).

4. Ramo de recuperação — §4.2

Três encoders candidatos (Legal-BERTimbau base, Legal-BERTimbau-STS, BGE-M3) avaliados sobre FAISS IndexFlatIP com similaridade de cosseno, contra baseline BM25 (tokenizer PT com normalização de acentos) e fusão híbrida RRF (k=60). Protocolo anti-overfit: seleção no dev, medida única no test.

4.1 Gold original (n=50/split)

Configuração	dev	test
BM25	0,70	0,74
FAISS Legal-BERTimbau base	0,36	—
FAISS Legal-BERTimbau STS	0,50	—
FAISS BGE-M3	0,86	0,86 [0,74–0,93]
Híbrido RRF BM25+BGE-M3	0,78	0,82

4.2 Gold ampliado (n=200/split) — resultado autoritativo

Configuração	dev	test
BM25	0.72	0.71
FAISS Legal-BERTimbau base	0.38	—
FAISS Legal-BERTimbau STS	0.46	—
FAISS BGE-M3	0.81	0.815 [0.755–0.863]
Híbrido RRF BM25+BGE-M3	0.76	—




Figura 7 — Hit Rate@5 no teste ampliado (n=200) com IC95 de Wilson; a linha tracejada é o critério §4.2 (0,85).

Veredito honesto: o critério $\geq 0,85$ NÃO foi atendido no gold ampliado (0,815). O 0,86 do n=50 era parcialmente efeito de amostra pequena — a expansão fez exatamente o seu papel metodológico. As decisões D2/D6 mantêm-se (o denso isolado continua vencendo o híbrido e o BM25), e o déficit de ~3,5 p.p. torna-se a justificativa técnica mensurada para fine-tuning do encoder — que só deve ocorrer sobre rótulos validados por especialista em dados reais, pois em sintético o modelo aprenderia os templates do gerador.

5. Geração estruturada e latência — §4.1, §4.3, §4.4

Mistral-7B (Q4) via Ollama nativo, 100% GPU (8,9 GB VRAM, ~120 tok/s), com saída forçada ao JSON Schema do LaudoLLM (parâmetro format), temperature 0, seed 42, num_ctx 4096, keep_alive 30 min. O prompt (§5.7) injeta metadados, evidências recuperadas (5 dispositivos + 2 casos similares) e a narrativa — sempre como dados, nunca como instruções.

Estágio	p50	p95	p99	máx
tabular	8 ms	15 ms	23 ms	43 ms
retrieval	575 ms	1 095 ms	1 368 ms	2 006 ms
llm	4 524 ms	7 839 ms	12 217 ms	14 858 ms
montagem	0 ms	0 ms	0 ms	0 ms
total	5 093 ms	8 368 ms	13 055 ms	15 710 ms




Figura 8 — Decomposição do p95 por estágio (empilhado) vs. p95 total medido vs. SLA de 8,5 s.

§4.1: p95 total 8.37 s < 8,5 s — ATENDIDO, com folga de ~130 ms. §4.3: 200/200 laudos válidos no schema na 1ª tentativa (100%).

5.1 Fundamentação com re-tentativa (§4.4)

A checagem determinística (checar_fundamentacao) valida cada citação contra os doc_id e artigos efetivamente recuperados. O modo de falha dominante não era alucinação de fonte: o modelo copiava o texto do dispositivo no campo artigo. Correção de prompt levou 64,5%% → 95%%.

Política implementada (resiliencia.gerar_fundamentado): laudo com violação é rejeitado internamente e reenviado UMA vez com um bloco [CORREÇÃO OBRIGATÓRIA] listando os erros; persistindo a falha, o laudo sai com a flag fundamentacao_pendente:revisao_humana — nunca é aceito em silêncio.

Medido em N=200: 20 retentativas (10% dos casos), fundamentação final 97% (6 laudos encaminhados à revisão humana). Custo: a cauda de latência absorve a 2ª geração — p99 subiu para 13.1 s, acima do SLA; o p95 permanece dentro. Mitigações possíveis: retry assíncrono via webhook (D5) ou teto de tokens na 2ª geração.

5.2 Exemplo ponta a ponta (executado, não ilustrado)

Caso EP013595 (verdadeiro positivo): 1 episódio anterior, ameaça de morte, arma de fogo, separação recente, descumprimento de medida protetiva, filhos comuns e controle coercitivo.

- LightGBM: score 0,901 → banda CRÍTICO (decisão determinística) → revisão humana obrigatória.
- Retrieval (BGE-M3/FAISS): art. 24-A da Lei 11.340/2006, art. 147 do CP e casos de apoio similares.
- Mistral-7B (1 tentativa): alegação — descumprimento de medida protetiva (art. 24-A) somado a ameaça (art. 147); garantia cita os dois dispositivos recuperados; refutação — sem atenuantes nos dados.
- Verificação determinística: 100% das citações íntegras; incerteza ALTA registrada pelo qualificador (cálculo padrão §5.2).

Caso EP017662 (falso negativo, incluído de propósito): controle coercitivo isolado → score 0,319 → banda MODERADO. O laudo ainda é gerado e fundamentado (art. 12, art. 147), mas a refutação e a incerteza ALTA sinalizam a fragilidade — demonstrando que a arquitetura reporta o erro em vez de escondê-lo. Texto integral dos dois laudos: `decisoos/exemplos_classificacao.md`.

6. Guardiões e resiliência — §4.6, §4.7

Detector de injeção (regex sobre padrões §6.2) + higiene de ingestão §6.3 (U+FFFD, truncamento, instrução embutida, contradição de metadados, duplicata): recall 1,0 e precisão 1,0 nos seeds. Em teste ponta a ponta com payloads injetados na narrativa: 12/12 laudos com schema válido e 1 eco de canário — reforçando que a defesa real mora na camada de entrada, que bloqueia 100%% dos padrões antes do modelo.

Probe CAV (D3): regressão logística sobre embeddings BGE-M3, 7 conceitos de risco (abuso de substâncias, ameaça de morte, arma de fogo, coerção, descumprimento de medida, escalada, separação recente), AUC 0,78–1,00 em holdout 5×75/25. Ressalva declarada: rótulos derivam dos mesmos templates que geram o texto — o probe valida o mecanismo, não a semântica externa.

Fase 4 — Guardiões: probe de conceitos + injeção de prompt




Figura 9 — AUC do probe CAV por conceito e desempenho do guardião de injeção.

Caos §4.7 (adaptado ao Ollama nativo — Docker Desktop inativo): porta morta → LaudoDegradado em 912 ms; soquete travado → 315 ms; kill durante a geração → 1.583 ms; circuit breaker abre após 3 falhas consecutivas e responde circuit_open na 4ª chamada. Todo degradado preserva o score tabular e marca revisão humana obrigatória.

7. Consolidação dos critérios §4

Critério	Medido	Veredito
§4.1 Latência p95 < 8,5 s	8,37 s (p99 13,1 s)	ATENDIDO no p95; p99 fora
§4.2 Hit Rate@5 $\geq$ 0,85	0,815 [0,755–0,863]	NÃO ATENDIDO
§4.3 Schema 1ª tentativa	200/200 (100%)	ATENDIDO
§4.4 Fundamentação	97% após retry; 6 flagged	ATENDIDO com flag
§4.5 AUC / ECE	0,751 / 0,012	ATENDIDO
§4.5 Anti-vazamento	controle flagra score_geracao	ATENDIDO
§4.6 Probe CAV	AUC 0,78–1,00	ATENDIDO
§4.6 Injeção / override	recall=precisão=1,0; matriz §6.4	ATENDIDO
§4.7 Resiliência	degradado < 1,6 s; breaker ok	ATENDIDO

Leitura de conjunto: o smoke test demonstra viabilidade técnica da arquitetura — 8 de 9 eixos atendidos — e produz um resultado negativo metodologicamente útil: o §4.2 quantifica o déficit do encoder genérico neste domínio e transforma 'precisamos melhorar' em 'faltam 3,5 p.p. de Hit Rate@5', motivação fundamentada para o fine-tuning com rótulos reais validados por especialista.

8. Limitações declaradas (§6.6)

- Dados 100% sintéticos: prevalência artificial ~50/50; rótulos fracos de relevância e de conceito derivam dos mesmos templates que geram o texto — as métricas medem coerência do pipeline, não validade externa.
- Ollama nativo: caos adaptado (porta morta, soquete travado, taskkill) em vez de docker pause; refazer com Docker Desktop ativo.
- Latência medida sequencialmente, modelo quente (keep_alive 30 min); carga a frio ~12,4 s fica fora do SLA e exige warm-up no deploy. Sem medição de concorrência.
- Webhook (canal assíncrono D5) não instrumentado.
- Gold set pendente de validação do especialista ($\geq 20\%$ dupla anotação, kappa reportado).
- BGE-M3 avaliado em CPU (torch CPU-only no Python 3.14); GPU deve reduzir o estágio de retrieval de ~0,5 s para ~50 ms.
- Limiares D8 provisórios: recalibração e novo ponto de operação são obrigatórios sobre dados reais.

8.1 Caminho para dados reais

O pipeline foi desenhado para a troca de fonte: iterar_episodios, montar_corpus, gerar_laudo, guardiões e harness de métricas são idênticos com dados reais. O refinamento previsto é: re-treino do LightGBM + recalibração de probabilidade + novos limiares; fine-tuning contrastivo do encoder sobre rótulos validados; eventual LoRA no Mistral para estilo de redação — nenhum deles altera os contratos.

Apêndice — Reprodutibilidade

Artefatos com hash registrado em dados/hash_registry.json. Scripts: treinar_tabular.py (Fase 1), baixar_corpus.py + gerar_corpus_sintetico.py + gerar_gold_set.py + avaliar_recuperacao.py (Fase 2), medir_latencia.py (Fase 3), testar_injecao.py + treinar_probe_cav.py + teste_caos.py (Fase 4), gerar_graficos.py + gerar_material_quali.py (figuras). Suíte de testes: 65 verificações pytest (incluindo matriz de override §6.4, detector de injeção, schema, fundamentação e política de retry).

Todos os números deste documento foram lidos dos artefatos persistidos (dados/metricas_*.json) no momento da geração — nenhum valor é citado de memória.

Documento gerado por scripts/gerar_pdf_metodologia.py